MyHike - Comparaison VM / Docker

Campagne réelle du 26/10/2026 | Akrem SOUSSI et Rémi CORTIAL

Même poste Windows, même code applicatif, mêmes fichiers SQL et comptes figés, même plan JMeter 5.6.3 / Java 8u511. Chaque couche dispose de 1 CPU et 2 Gio de RAM (système invité compris pour les VM). Un seul déploiement fonctionne à la fois ; Docker Desktop est arrêté pendant les mesures VM. L'ordre des campagnes est VM r1, Docker r1, Docker r2, VM r2. Une sauvegarde privée et une réinitialisation SQL précèdent chaque série.

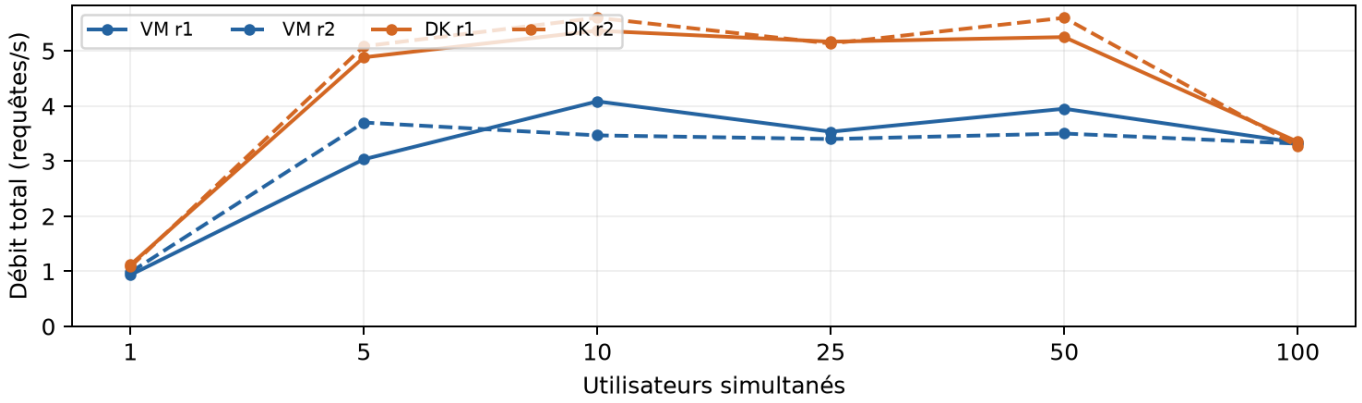
Une itération ouvre une session puis consulte 20 refuges authentifiés ; assertions HTTP, contenu et session, attente de 500 à 1 000 ms avant chaque requête. Paliers : 1, 5, 10, 25, 50 et 100 utilisateurs. Montée 10 s, fenêtre mesurée 60 s après le marqueur + 11 s, pause 10 s entre paliers. Les requêtes sont retenues par leur heure de départ ; leur durée complète est conservée. Les contrôles positif et mot de passe incorrect sont archivés pour chaque série.

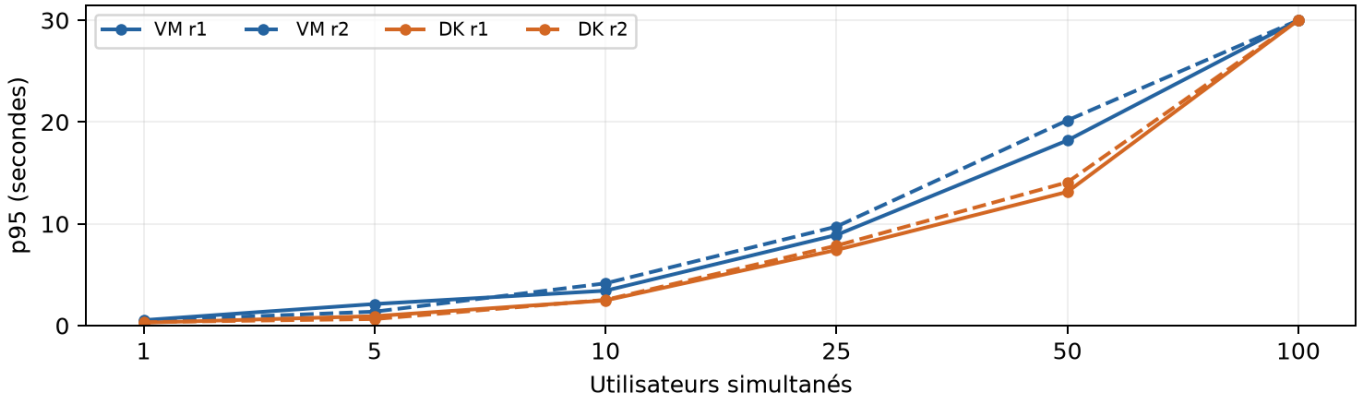
Grandeur	VM	Docker
Meilleur débit observé sans erreur	3,77 req/s (10 u.)	5,48 req/s (10 u.)
p95 moyen à 10 utilisateurs	3,79 s	2,50 s
Erreurs moyennes à 100 utilisateurs	100,00 %	99,50 %
Premier palier proche du plateau (1)	10 utilisateurs	5 utilisateurs
Composant limitant observé	Backend : CPU / pool	Backend : CPU / pool
Démarrage complet, médiane de 3	63,53 s	26,86 s
Somme RSS hôte au repos, médiane	2229 Mio	3472 Mio
Pic mémoire backend observé	972 Mio	869 Mio

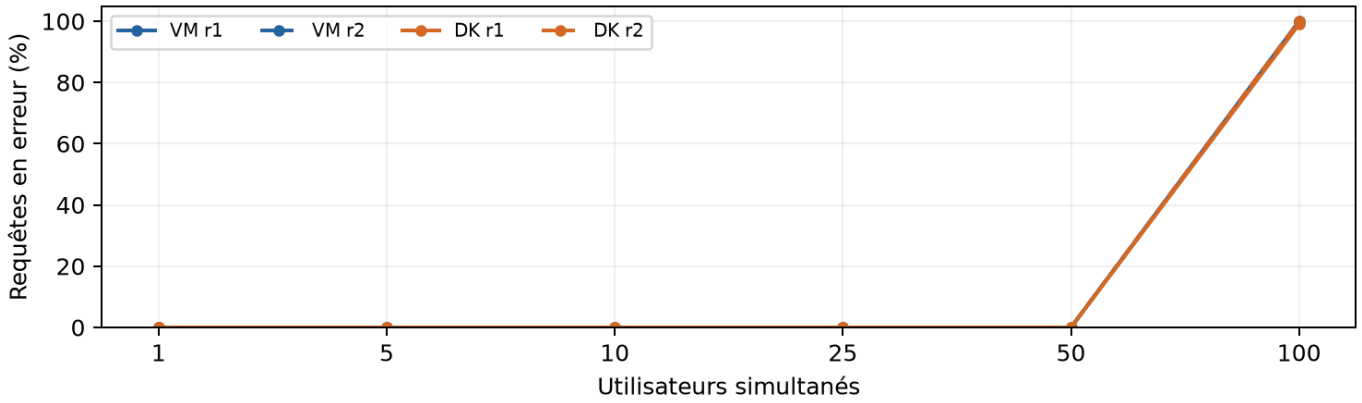
La somme RSS mesure les processus hôtes identifiés, avec possibles pages partagées ; elle ne représente pas la RAM allouée. Le démarrage VM va de trois VM éteintes à l'API saine ; Docker inclut le démarrage de son moteur Linux puis des trois conteneurs. Ces durées comprennent l'orchestration et la résolution des contrôles de santé. Le repos est relevé après campagne et redémarrage. (1) Premier palier atteignant 90 % du meilleur débit moyen réussi : repère descriptif, pas un seuil de service acceptable.

VM : 470 à 736 req/s sur /index.html. DK : 5887 à 6318 req/s sur /index.html. Ce sont des bornes de capacité du couple injecteur/proxy, pas une mesure isolée du plafond de Java. Les métriques de Java et les erreurs sont conservées.

Courbes des deux répétitions







Le débit total inclut les requêtes échouées. À forte charge, il faut lire simultanément le taux d'erreur ; le p95 des échecs reflète souvent le délai d'attente client.

Résultats et répétabilité

Déploiement	u.	Débit r1 / r2	p95 r1 / r2 (s)	Erreurs r1 / r2 (%)
VM	1	0,93 / 0,98	0,54 / 0,50	0,0 / 0,0
VM	5	3,03 / 3,70	2,13 / 1,37	0,0 / 0,0
VM	10	4,08 / 3,47	3,43 / 4,15	0,0 / 0,0
VM	25	3,53 / 3,40	8,90 / 9,73	0,0 / 0,0
VM	50	3,95 / 3,50	18,19 / 20,16	0,0 / 0,0
VM	100	3,33 / 3,32	30,00 / 30,00	100,0 / 100,0
DK	1	1,12 / 1,08	0,29 / 0,34	0,0 / 0,0
DK	5	4,88 / 5,08	0,93 / 0,65	0,0 / 0,0
DK	10	5,37 / 5,60	2,47 / 2,53	0,0 / 0,0
DK	25	5,17 / 5,13	7,43 / 7,86	0,0 / 0,0
DK	50	5,25 / 5,60	13,14 / 14,08	0,0 / 0,0
DK	100	3,35 / 3,27	30,01 / 30,02	99,0 / 100,0

Écart relatif = |r1 - r2| / moyenne × 100, calculé séparément sur le débit et le p95. Dépassement du seuil de 10 % : VM 5 u., VM 10 u., VM 50 u., DK 1 u., DK 5 u.. Ces paliers restent publiés ; aucun meilleur essai n'est sélectionné pour masquer la variation.

Les moyennes de la synthèse sont des moyennes des deux statistiques par essai, pas des percentiles recalculés sur un mélange de séries. Le détail complet, y compris les requêtes réussies par seconde, est fourni dans synthese.csv.

Validation GUI réalisée manuellement par l'utilisateur le 26 octobre 2026. Les captures et relevés montrent HTTP 200 pour la connexion et la consultation nominales, puis HTTP 401 et des assertions échouées avec le mot de passe incorrect. Les preuves sont conservées dans captures/.

Traçabilité : configuration.json (empreintes), PROTOCOLE.md, etapes/*-resultat.json, *-serveur.jsonl et *-backend.txt, calibration/, baseline-vm.json et baseline-dk.json. Les CSV bruts vm/dk portant l'identifiant 20261026-152151 sont dans bruts/charge ; l'étalonnage est dans bruts/etalonnage. Les données anciennes restent inchangées.

Interprétation et limites

1. De combien les déploiements diffèrent-ils ?

Le meilleur débit sans erreur observé vaut 3,77 req/s en VM et 5,48 req/s sous Docker, aux charges indiquées page 1. À 10 utilisateurs, le p95 moyen est respectivement 3,79 s et 2,50 s. Ces moyennes décrivent deux essais ; ce ne sont pas des garanties de capacité durable.

2. Quelles propriétés peuvent expliquer l'écart ?

Les VM exécutent trois systèmes invités, tandis que les conteneurs partagent le noyau de la VM Linux de Docker Desktop. Le coût de l'ordonnancement et du réseau diffère. Les versions de Python (VM 3.12 / Docker 3.14), MySQL (8.0 / 8.4) et Nginx diffèrent également : les résultats comparent ces installations concrètes, sans isoler l'effet de la virtualisation.

3. Quel composant limite le service ?

VM : CPU moyen backend jusqu'à 95,1 % d'un cœur, contre 13,6 % pour MySQL ; maximum 16 connexions, surveillance comprise. Les journaux confirment un pool SQLAlchemy de 5 + 10 connexions épuisé. DK : CPU moyen backend jusqu'à 102,3 % d'un cœur, contre 8,3 % pour MySQL ; maximum 16 connexions, surveillance comprise. Les journaux confirment un pool SQLAlchemy de 5 + 10 connexions épuisé. Le pool est une limite applicative : cela ne prouve pas la saturation du moteur MySQL. Les courbes et les métriques par palier permettent de distinguer le ralentissement préalable de l'échec à forte charge. Après la première surcharge Docker, le backend était unhealthy sans OOM ; un redémarrage hors mesure a précédé la réinitialisation de la série suivante.

4. Que ne démontrent pas ces mesures ?

Deux répétitions de 60 s ne couvrent ni l'endurance ni la disponibilité, les pannes ou une distribution multi-hôtes. Le poste héberge aussi l'injecteur ; les tâches de fond, caches et températures ne sont pas parfaitement contrôlés. Les temporisations client plafonnent les latences d'échec autour de 30 s. Les versions et les modalités de quotas/swap diffèrent. Les anciennes mesures sur le PC de Rémi restent historiques et sont exclues de cette comparaison.

Conclusion méthodologique : les paliers instables sont explicitement signalés. Le critère de répétabilité n'est pas satisfait à tous les paliers ; les résultats ne sont pas présentés comme une validation complète de toutes les exigences.